

InVitro Fertilization Genetic Algorithm

Airton Bordin Junior

[airtonbjunior@gmail.com]

Metaheurísticas - Prof. Dr. Celso Gonçalves Camilo Junior

Mestrado em Ciência da Computação 2017/2

Universidade Federal de Goiás (UFG) - Instituto de Informática – Novembro/2017

Programação


- Introdução
- Algoritmos genéticos
- InVitro Fertilization Genetic Algorithm
- Referências





Algoritmos genéticos

Principais
diferenças com
métodos
tradicionais




Trabalham com uma codificação do conjunto de parâmetros e não com os próprios parâmetros;

Trabalham com uma população e não com um único ponto;

Utilizam informações de custo ou recompensa e não derivadas ou outro conhecimento auxiliar;

Utilizam regras de transição probabilísticas e não determinísticas.



Algoritmos genéticos

Algumas características

Paralelo: mantém uma população de soluções que podem ser avaliadas simultaneamente;

Global: AGs não usam somente informações locais, logo não necessariamente ficam presos em máximos locais;

Não totalmente aleatório: usam informações da população atual para determinar o próximo estado de busca;

Não afetados por descontinuidades: não usam informações de derivadas nem necessitam informações de seu entorno;

Funções: Lidam com funções discretas e contínuas.



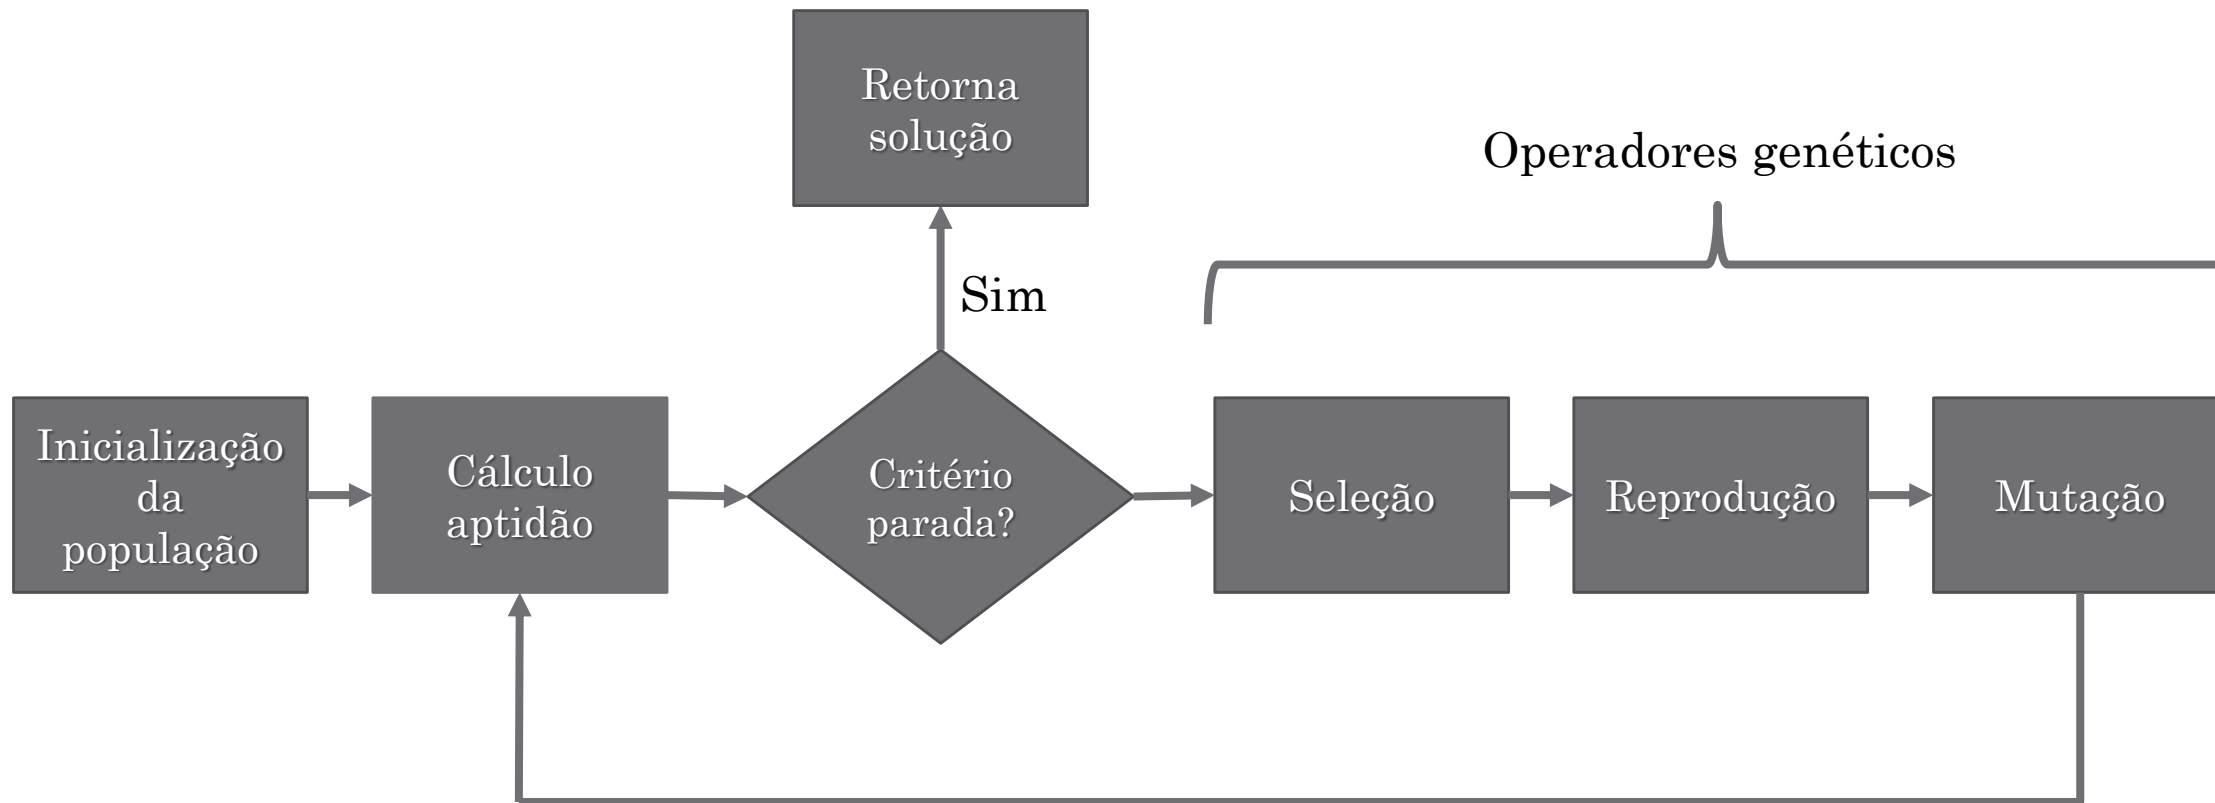
Algoritmos genéticos

Requisitos implementação de um AG

- Representação das possíveis soluções do problema no formato de código genético;
- População inicial com diversidade suficiente;
- Método para medir a qualidade da solução;
- Critério de escolha das soluções que continuam;
- Procedimento para introduzir algumas alterações periódicas na população.



Algoritmos genéticos





Inicialização da população



- Ponto de partida: representação do problema;
- Definição da estrutura do cromossomo;
- Depende do tipo de problema a ser tratado;
- Exemplos
 - Vetor de bits;
 - Vetor de números (inteiros, reais);
 - Permutação de símbolos, etc.





Inicialização da população

- Exemplo: representação em bits





Inicialização da população

- Geralmente a inicialização da população é feita de forma randômica;
- Cada indivíduo gerado é uma possível solução para o problema.

Exemplo: população de 9 indivíduos gerada randomicamente

111111

101010

000111

110110

100110

010100

100001

100000


110000





Cálculo aptidão



- Determinada através da função objetivo;
- Depende do problema a ser tratado;
- Mede o quão próximo um indivíduo está da solução desejada;
- A função deve ser escolhida cuidadosamente e embutir o máximo de conhecimento sobre o problema a ser resolvido.





Seleção


- Tentativa de simular o mecanismo de seleção natural que atua sobre as espécies biológicas;
- Os pais mais capazes geram mais filhos
 - Porém, os menos aptos também podem gerar descendentes.





Seleção

- Privilegiar indivíduos com função de avaliação alta, sem desprezar completamente aqueles com função de avaliação extremamente baixa
 - Até indivíduos com péssima avaliação podem ter características genéticas que sejam favoráveis à criação de um "super indivíduo".






Seleção

- Privilegiar indivíduos com função de avaliação alta, sem desprezar completamente aqueles com função de avaliação extremamente baixa


• Até indivíduos com péssima avaliação podem ter características genéticas que sejam favoráveis à criação de um "super indivíduo".






Seleção

- Método comum: Roleta (*Roulette Wheel*);
- Probabilidade de seleção de um cromossomo é diretamente proporcional à sua aptidão.



■ "000001" ■ "000011" ■ "000100" ■ "000110"



Cromossomo	Função x^2	% roleta
000001	1	1.6%
000011	9	14.5%
000100	16	25.8%
000110	36	58%





Seleção



- Outras formas utilizadas para a seleção
 - **Dizimização**
 - Ordena os cromossomos de acordo com o seu valor de aptidão e remove um número fixo de indivíduos que possuem baixo valor de aptidão;
 - Dentre os “sobreviventes”, escolhem-se os pais de forma aleatória.





Seleção


- Outras formas utilizadas para a seleção
 - **Torneio**
 - Escolhe-se n (geralmente 2) indivíduos aleatoriamente;
 - O melhor é selecionado;
 - Não é proporcional a aptidão.





Cruzamento

- Troca de segmentos entre “pares” de cromossomos selecionados para originar os novos indivíduos da geração seguinte;
- Propagar as características positivas dos indivíduos mais aptos da população por meio da troca de segmentos de informações entre os mesmos, originando novos indivíduos.





Cruzamento


- Operador genético predominante;
- Aplicado com taxa de probabilidade maior que a taxa de mutação;
- Tipos de cruzamento muito utilizados:
 - Cruzamento de ponto único;
 - Cruzamento de ponto duplo;
 - Cruzamento de pontos aleatórios.






Cruzamento

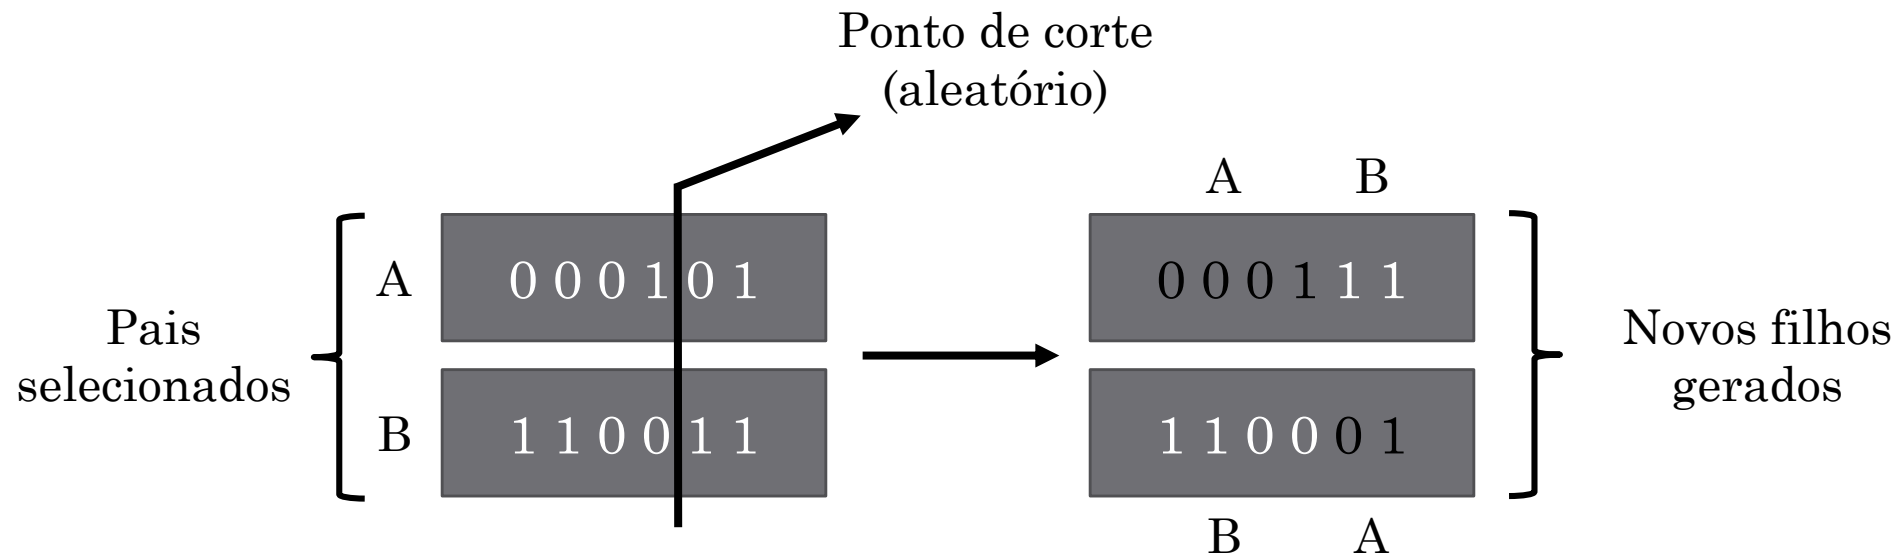
- Cada indivíduo com n genes possui $n-1$ pontos de corte;
- Em um indivíduo com codificação binária, cada bit é um gene.





Cruzamento


- Ponto único – Um ponto é escolhido e, à partir desse ponto, as informações genéticas dos pais serão trocadas.





Cruzamento

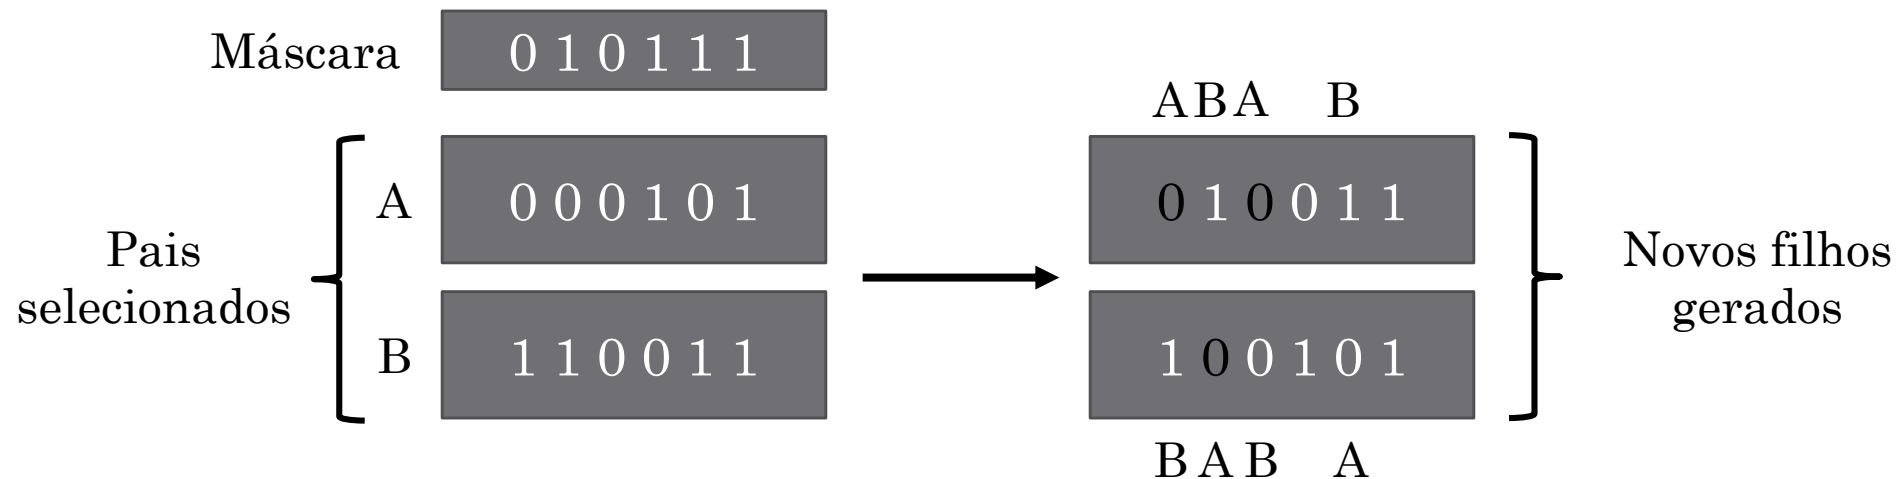
- Ponto duplo – Dois pontos são escolhidos e as informações genéticas dos pais serão trocadas.





Cruzamento


- Pontos aleatórios – Usa uma máscara de bits – bit 0 pega gene de um dos pais e bit 1 o contrário.





Mutação


- Modificações em determinadas propriedades genéticas de forma aleatória;
- Introdução e manutenção da diversidade genética da população;
- Assim como na natureza, deve acometer uma pequena parcela da população
 - Probabilidade de **0,1%** a **5%** na maior parte dos casos.





Mutação

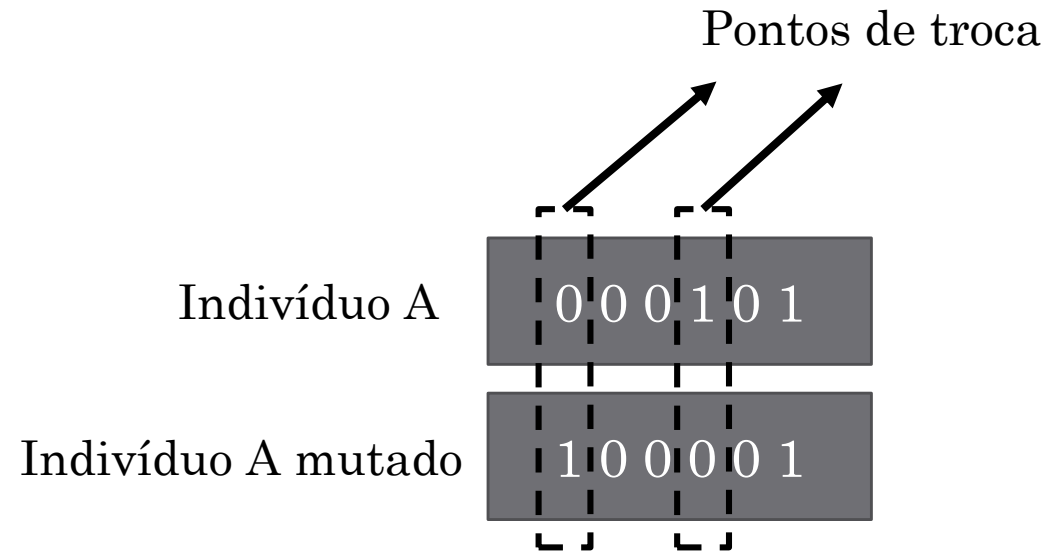
- Mutação aleatória





Mutação

- Mutação por troca



InVitro Fertilization Genetic Algorithm

InVitro Fertilization Module (IVFm)



InVitro Fm

- Processo utilizado pelo Algoritmo Genético segue um ciclo de processamento
 - Cada iteração cria uma nova geração de indivíduos
- Em cada geração, novos indivíduos substituem outros existentes;
- Muitos indivíduos descartados contém “material genético” importante para a busca.




InVitro Fm

- Os indivíduos descartados nem sequer passam pelo processo de reprodução;
- Alguns deles são gerados e descartados sem contribuir para a evolução;
- A cada geração, informações são perdidas antes mesmo de serem analisadas.

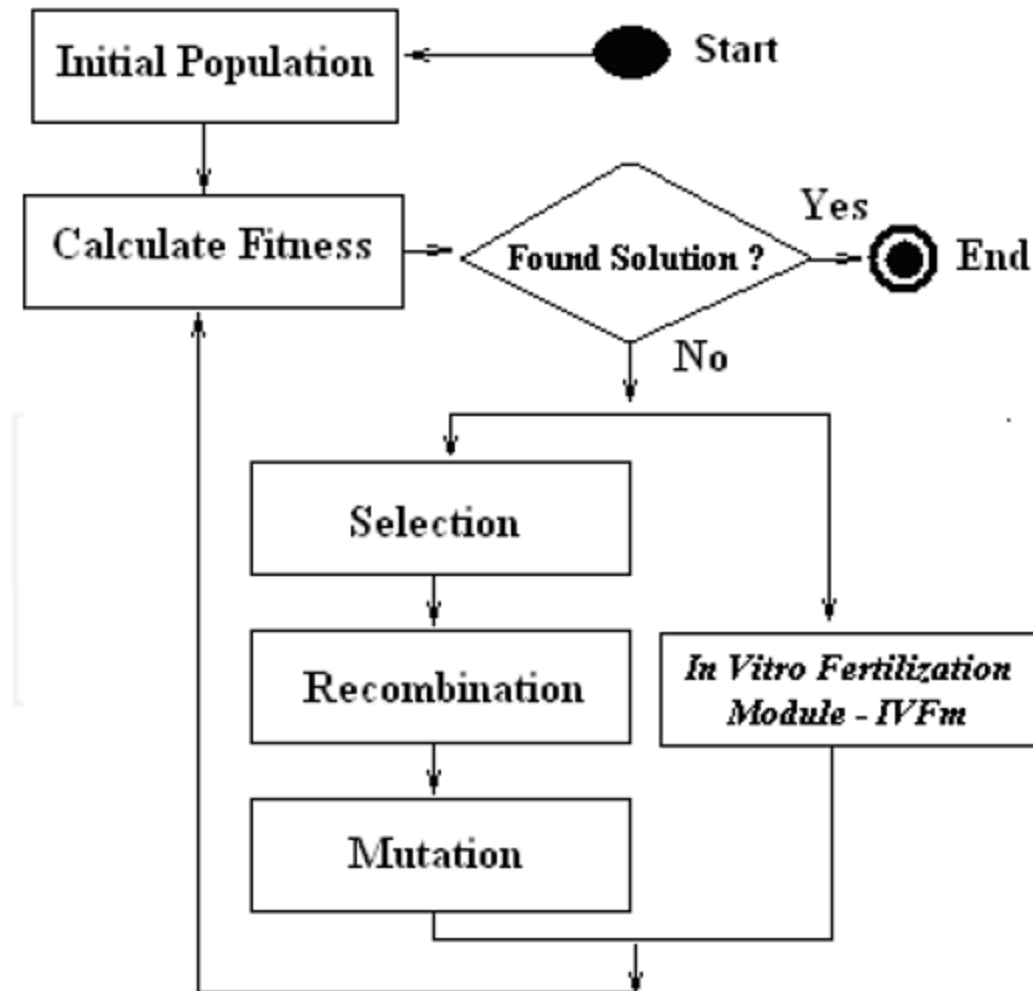


InVitro Fm

- IVFm recombina os cromossomos da população e de novos indivíduos
 - Melhorar a exploração da informação
- Executa em um fluxo paralelo ao AG;
 - Recebe como entrada uma parte da população e retorna um indivíduo que pode ser melhor
- Acelerar o processo evolutivo do AG.

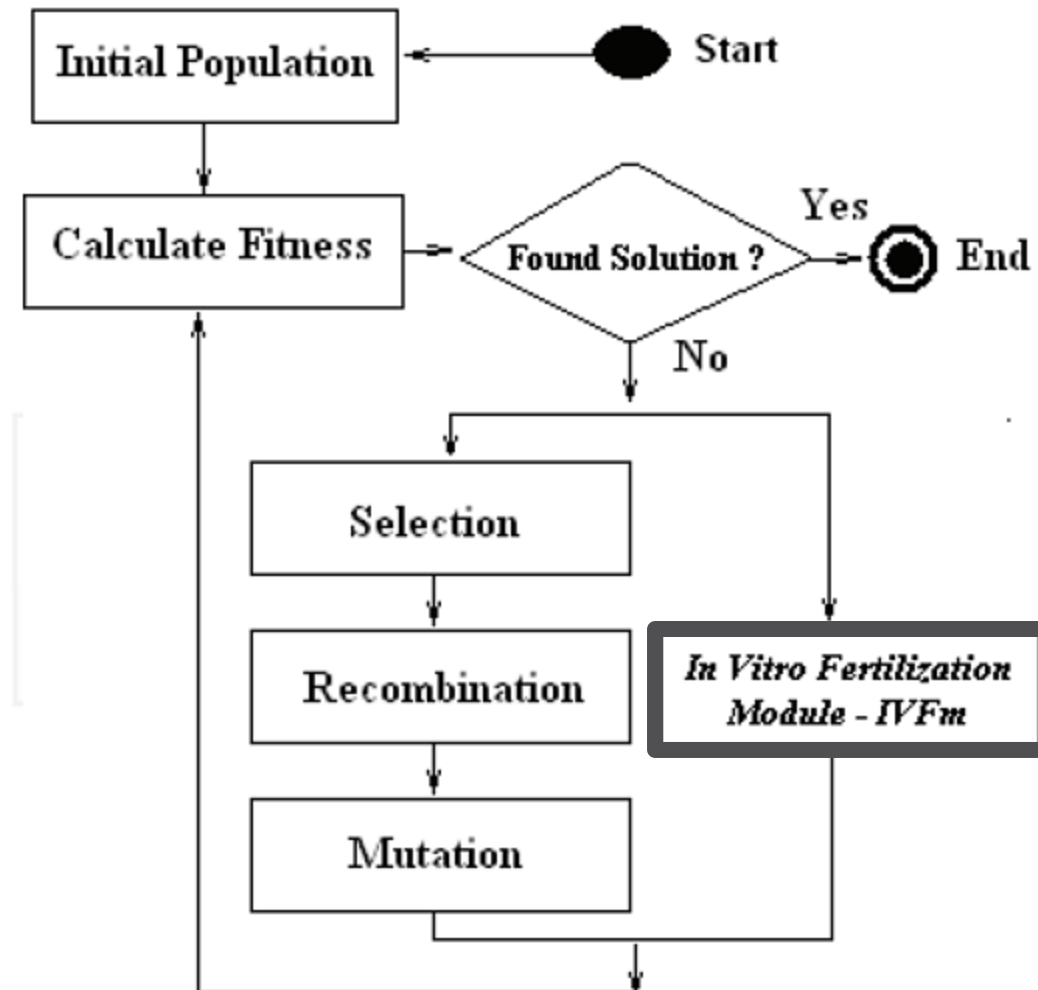


InVitro Fm





InVitro Fm





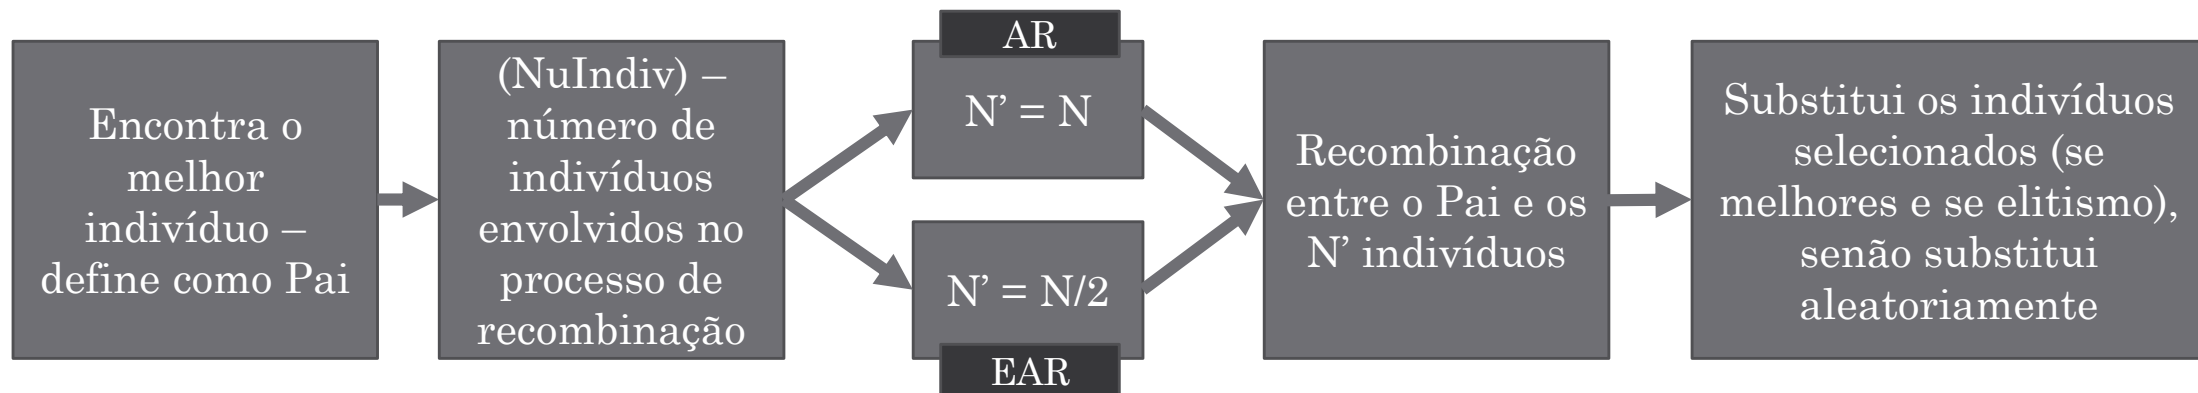
InVitro Fm


- Ideia geral: recombinação genética de partes do indivíduo como melhor
 - Se gerar um indivíduo melhor, substitui o melhor atual, caso contrário não há interferência.
- Dois grupos de operadores
 - Material genético original: AR
 - Material genético alterado: EAR (T/P/N)



InVitro Fm

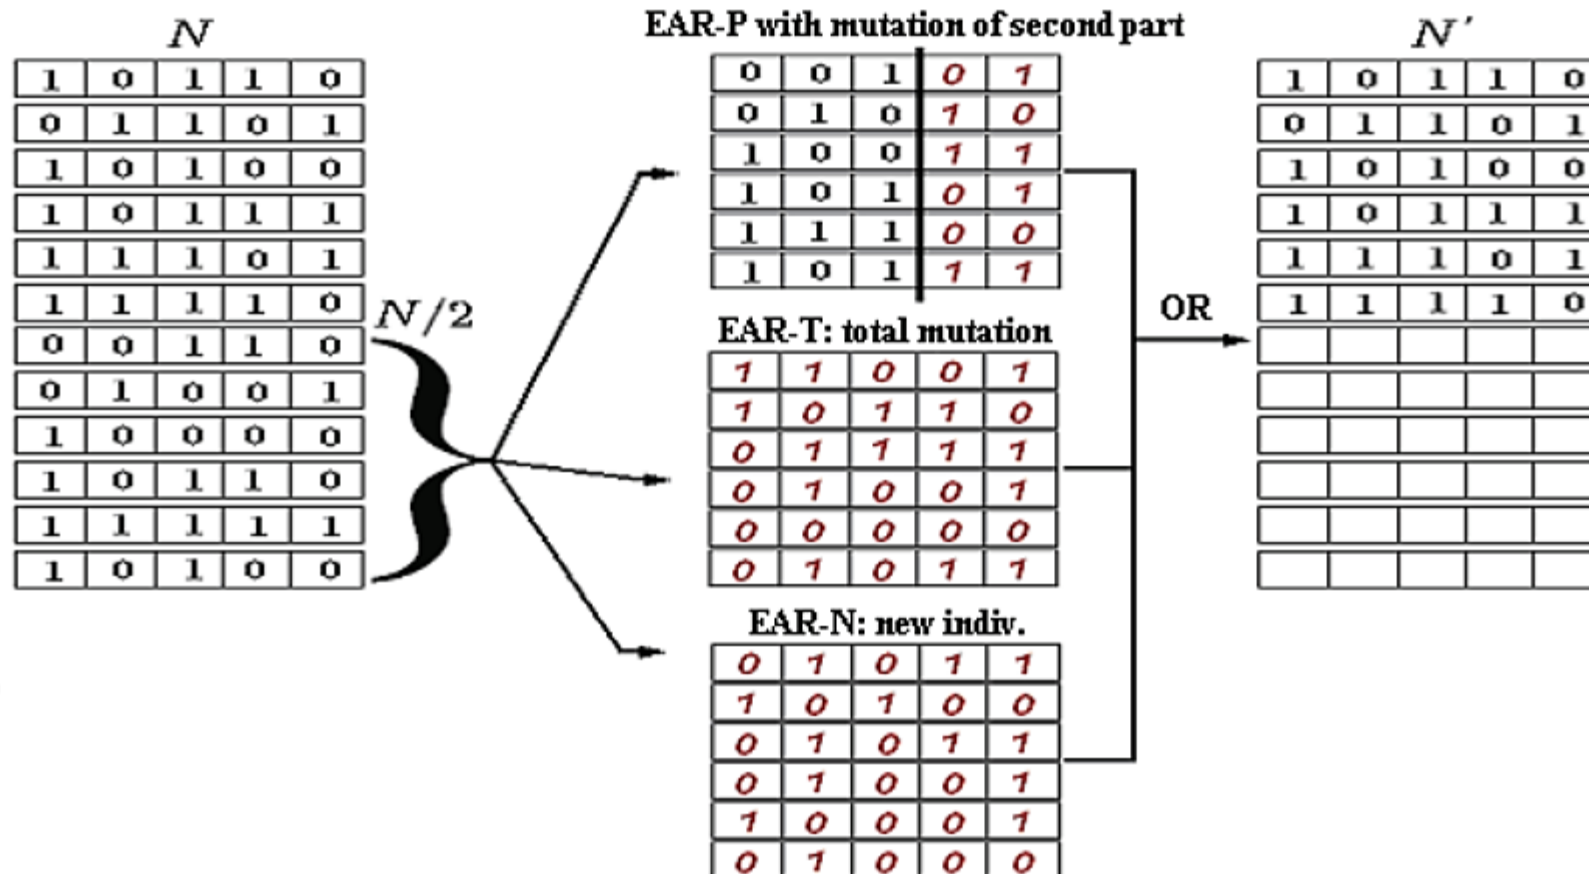
- Fluxo geral
 - Definidos uma vez no início do processo do AG
 - Divisão do material genético (fenotípico)
 - *Genetic Material Division to be exchanged.*
 - Porção da população usada pelo IVFm.
 - Após receber a população de indivíduos:






InVitro Fm

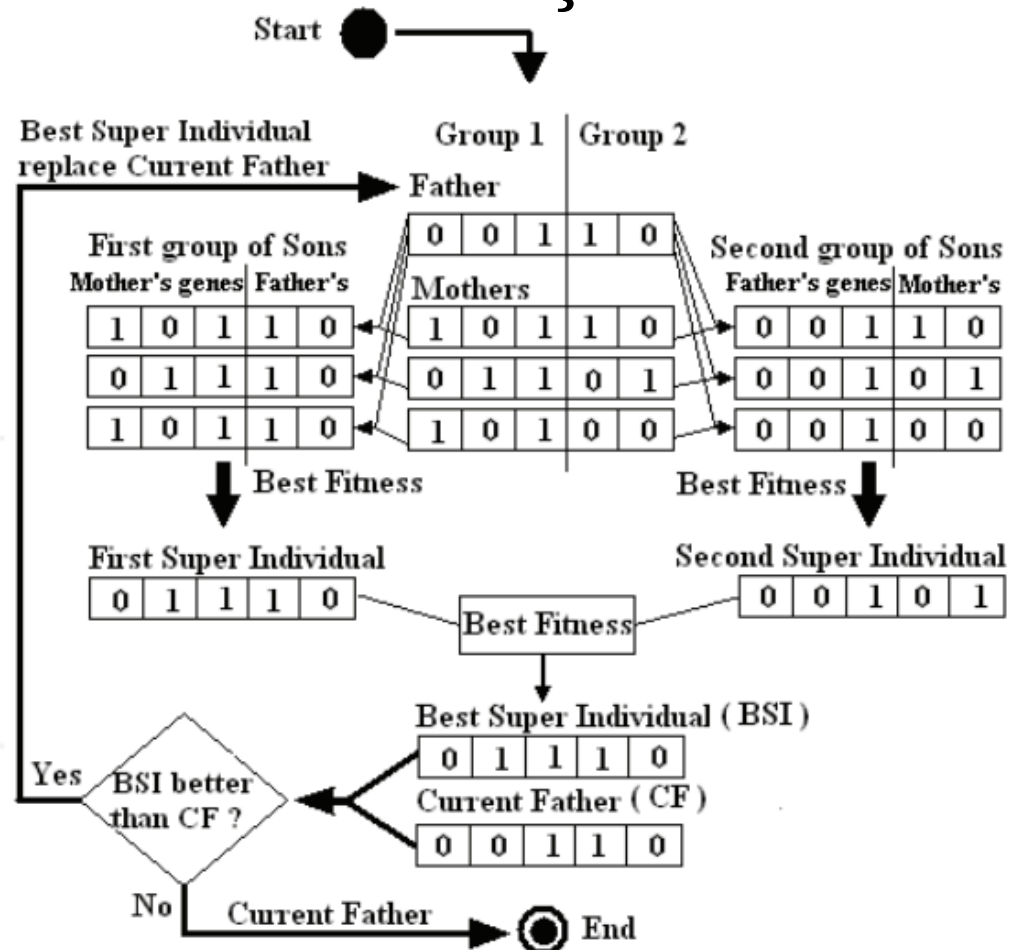
- Operador EAR (P/T/N)





InVitro Fm


- Processo de recombinação





InVitro Fm

- Experimentos
 - Rastrigin's function



$$f(x) = nA + \sum_{i=1}^n (x_i^2 - A \cos(2\pi x_i)); \forall i \in [1..n], x_i \in [-5.12, 5.12]$$



InVitro Fm

- Experimento 1 - configuração

Experiment 1							
Scenario	GA			IVFm		Function	
1.1	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	50	34	GO or 250 G	4	45	2	10
1.2	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	50	34	GO or 250 G	4	45	2	50



InVitro Fm

- Experimento 2 - configuração

Experiment 2							
Scenario	GA			IVFm		Function	
2.1	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	30	34	GO or 250 G	2	27	2	10
2.2	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	10	34	GO or 250 G	2	9	2	10
2.3	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	5	34	GO or 250 G	2	4	2	10



InVitro Fm


- Experimento 3 - configuração

Experiment 3							
Scenario	GA			IVFm		Function	
3.1	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	50	34	GO or 250 G	4	45	2	10
3.2	Pop	NuG	SC	DGM	NuIndiv	Variables	A
	50	170	GO or 250 G	10	45	10	10



In Vitro Fm


- Experimento 1 - resultados





In Vitro Fm


- Experimento 2 - resultados





In Vitro Fm

- Experimento 3 - resultados





InVitro Fm

- Operadores mais eficientes/eficazes (ordem)
 1. EAR-N
 2. EAR-T
 3. EAR-P
 4. AR
- Bons resultados do operador EAR-N justificam-se pela forma de balanceamento da exploração e intensificação do espaço de busca.



Referências

- CAMILO-JR, C. G., YAMANAKA, K. In Vitro Fertilization Genetic Algorithm
- LUCAS, D.C. Algoritmos Genéticos: Uma Introdução
- CARVALHO, A. P. L. Algoritmos Genéticos
- ROSA, T. O.; LUZ, H. S. Conceitos Básicos de Algoritmos Genéticos: Teoria e Prática
- PACHECO, M. A. C. Algoritmos Genéticos: Princípios E Aplicações
- NETO, S. P Computação Evolutiva: Desvendando os Algoritmos Genéticos
- MIRANDA, M. N. Algoritmos Genéticos: Fundamentos e Aplicações
- CRUZ, A. J. O. Algoritmos Genéticos
- LIMA, E. S. Algoritmos Genéticos
- PARREIRAS, R. O. Algoritmos Evolucionários e Técnicas de Tomada de Decisão em Análise Multicritério
- MANOEL, H. P. Algoritmos Genéticos
- ZUBEN, F. V. Representação e Operadores Evolutivos
- MONÇÃO, A. C. B. L. Uma Abordagem Evolucionária para o Teste de Instruções SELECT SQL com o uso da Análise de Mutantes