

Aplicando Programação Genética na Geração de Classificadores de Sentimento

Airton Bordin Junior

airtonbjunior@gmail.com

Prof. Dr. Nádia Félix Felipe da Silva


nadia@inf.ufg.br

Prof. Dr. Celso Gonçalves Camilo Junior

celso@inf.ufg.br

Prof. Dr. Thierson Couto Rosa

thierson@inf.ufg.br



CBIC 2017



Roteiro

- Introdução
 - Contextualização
 - Problema
 - Objetivo
- Conceitos
- Materiais e Métodos
- Análise dos Resultados
- Conclusão



Introdução - Contextualização

- Web é utilizada como plataforma para debates, opiniões, avaliações, etc.
- Instituições, pessoas e empresas tem interesse em saber qual a opinião sobre determinado tema

Introdução - Contextualização

- A Análise de Sentimentos (AS) é uma linha de pesquisa que tem por objetivo a **classificação das emoções de um determinado texto**, geralmente como positivo, negativo ou neutro

Introdução - Problema

- Para que um classificador tenha bons resultados, deve levar em conta o contexto/domínio
- Custo da construção de um classificador para um contexto específico (geralmente manual)

Introdução - Objetivo

- Classificador de sentimentos pode ser visto como um **modelo**
- Criação do classificador pode ser abordada como um **problema de otimização**
- Geração de modelos competitivos de classificação de sentimentos usando Programação Genética

Roteiro

- Introdução
 - Contextualização
 - Problema
 - Objetivo
- **Conceitos**
- Materiais e Métodos
- Análise dos Resultados
- Conclusão




Análise de Sentimentos

- Principais abordagens
 - **Aprendizado de máquina**
 - Aprendizado supervisionado
 - **Análise Léxica**
 - Características léxicas
 - Dicionário Léxico
 - **Híbrida**



Programação Genética

- Resolução de problemas, de forma automatizada, sem demandar conhecimentos detalhados sobre a solução

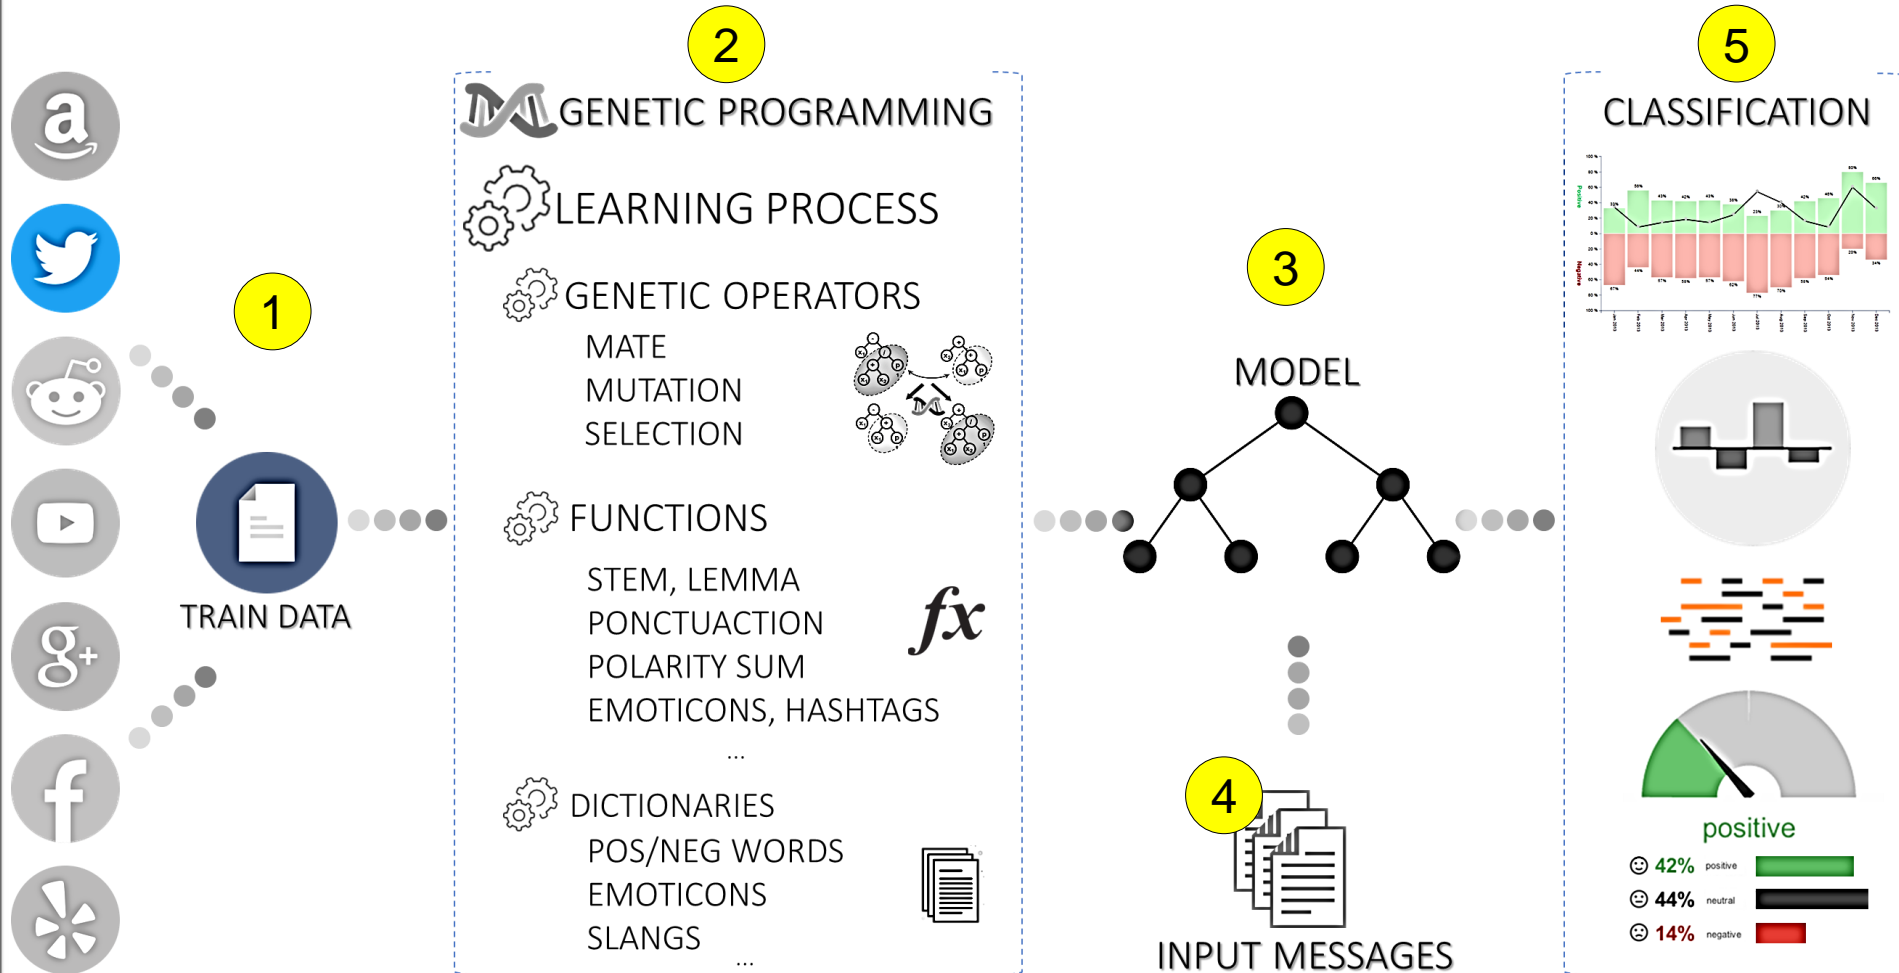


Roteiro

- Introdução
 - Contextualização
 - Problema
 - Objetivo
- Conceitos
- **Materiais e Métodos**
- Análise dos Resultados
- Conclusão



Materiais e Métodos




Materiais e Métodos

- *Benchmark* utilizado: SemEval 2014
 - Base de treinamento
 - Base de teste
 - Ranking dos trabalhos
- Dicionários
 - *Opinion Lexicon*
 - **2006** palavras positivas, **4800** palavras negativas
 - Emoticons
 - **186** emoticons positivos, **166** emoticons negativos


Materiais e Métodos – Base treino

■ Positivo ■ Negativo ■ Neutro



Materiais e Métodos – Base teste

■ Positivo ■ Negativo ■ Neutro



Materiais e Métodos

■ Parametrização Programação Genética

Modelo	População	Gerações	Crossover	Mutação
A	50	500	35%	15%
B	50	600	95%	35%
C	100	650	45%	25%

Materiais e Métodos

■ Funções Programação Genética (20)

- positiveHashtags
- negativeHashtags
- positiveEmoticons
- negativeEmoticons
- polaritySum
- hashtagPolaritySum
- emoticonsPolaritySum
- positiveWords
- negativeWords
- hasHashtag
- hasEmoticons
- if_then_else
- stemmingText
- removeStopWords
- removeLinks
- removeEllipsis
- removeAllPunctuation
- replaceNegatingWords
- replaceBoosterWords
- boostUpperCase



Materiais e Métodos - *Baseline*

- Modelo simples criado para comparação com os modelos gerados
- Soma simples das polaridades de cada palavra da frase
- Muito utilizado em classificadores criados manualmente



Roteiro


- Introdução
 - Contextualização
 - Problema
 - Objetivo
- Conceitos
- Materiais e Métodos
- **Análise dos Resultados**
- Conclusão




Materiais e Métodos - *Baseline*

- Métricas mais utilizadas para avaliação dos modelos
 - Acurácia
 - Precisão
 - *Recall*
 - F1
- Métrica utilizada: F1
 - Média harmônica de Precisão e *Recall*

■ Baseline ■ Modelo A ■ Modelo B ■ Modelo C



■ Baseline ■ Modelo A ■ Modelo B ■ Modelo C



All messages

1º	68.77	NRC Canada
2º	66.27	CISUC KISS
3º	65.55	CooooIII
...		
22º	58.32	Este trabalho
...		
49º	45.27	UMCC_DLSI
50º	38.72	Warwick
51º	36.05	DAEDALUS



1º	68.77	NRC Canada
2º	66.27	CISUC KISS
3º	65.55	CooooIII

22º	58.32	Este trabalho
-----	-------	---------------

49º	45.27	UMCC_DLSI
50º	38.72	Warwick
51º	36.05	DAEDALUS

Roteiro

- Introdução
 - Contextualização
 - Problema
 - Objetivo
- Conceitos
- Materiais e Métodos
- Análise dos Resultados
- Conclusão



Conclusão

- Alguns modelos apresentaram melhores resultados em determinadas sub-bases de teste
- Em todas as bases o F1 médio dos modelos gerados pela PG foram superiores ao *baseline*



Trabalhos futuros

- Melhorar inicialização da população
- Incluir novas funções para uso da Programação Genética
- Testar novas combinações de parâmetros do algoritmo
- Ampliar conjunto de dicionários
- Ampliar base de treinamento



Aplicando Programação Genética na Geração de Classificadores de Sentimento

Airton Bordin Junior

airtonbjunior@gmail.com

Prof. Dr. Nádia Félix Felipe da Silva


nadia@inf.ufg.br

Prof. Dr. Celso Gonçalves Camilo Junior

celso@inf.ufg.br

Prof. Dr. Thierson Couto Rosa


thierson@inf.ufg.br




CBIC 2017



Resultados – Modelo A



Resultados – Modelo B



Resultados – Modelo C

